

Projet MAP411 – X2015

# Applications de méthodes d'optimisation à la résolution des EDP

Sujet proposé par Nicolas Augier – nicolas.augier@ens-cachan.fr

Lucas Lugão Guimarães – lucas.lugao-guimaraes@polytechnique.edu  
Alexandre Ribeiro João Macedo – alexandre.macedo@polytechnique.edu

## I. Méthodes de gradient

### I.1. Gradient à pas constant

I.1.1. La figure 1 montre les lignes de niveau de la fonction de Rosenbrock,

$$J(u_1, u_2) = (u_1 - 1)^2 + 100(u_1^2 - u_2)^2, \quad (1)$$

dans le rectangle  $(u_1, u_2) \in [-1.5, 1.5] \times [0.5, 1.5]$ .




FIGURE 1 – Lignes de niveau de  $J$ .

I.1.2. On applique la méthode de gradient à pas constant  $u_{k+1} = u_k - \rho \nabla J(u_k)$  ou, pour  $u_k = (u_{k1}, u_{k2})$ , on a  $\nabla J(u_k) = (400u_{k1}^3 + 2u_{k1} - 400u_{k1}u_{k2} - 2, 200u_{k1}^2 - 200u_{k2})$ . Pour les valeurs numériques  $u_0 = (1, 0)$  et  $\rho = 0.002$ , et le critère d'arrêt  $J(u_{k+1}) < 10^{-3}$ , on a besoin de 2764 itérations. La figure 3 montre les lignes de niveau de l'équation 1 et le parcours du méthode avant l'arrêt.




FIGURE 2 – Surface plot de la fonction de Rosenbrock.

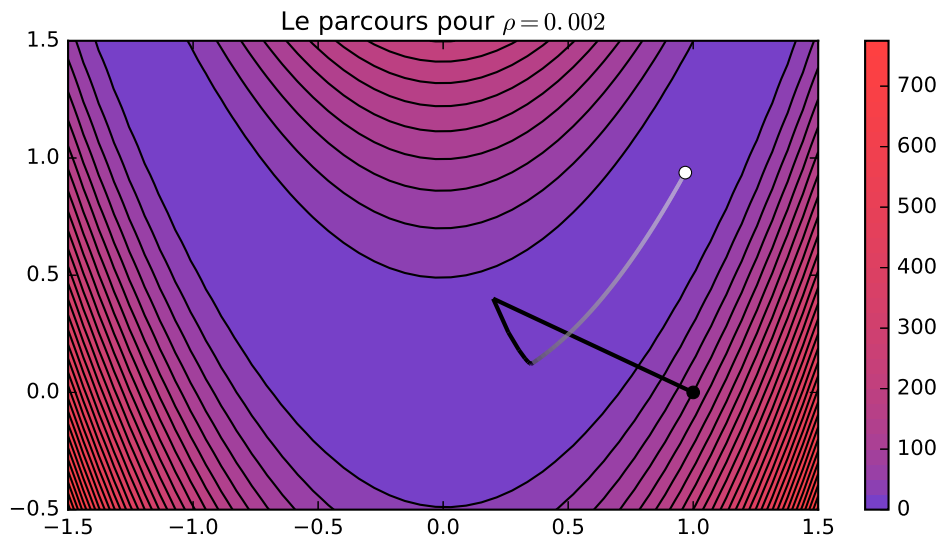


FIGURE 3 – Parcours du méthode de gradient à pas constant.

**I.1.3.** Si on applique la méthode pour  $\rho = 0.0045$  et pour  $\rho = 0.01$ , on a que le méthode diverge. Pour la valeur  $\rho = 0.0045$ , la méthode oscille en tour du minimum et ne converge pas. Pour la valeur  $\rho = 0.01$ , la première itération est déjà très loin du point de minimum et il ne reviens pas.




FIGURE 4 – Le parcours du méthode de gradient à pas constant  $\rho = 0.0045$  et  $\rho = 0.01$ .

Toutes les figures et résultats ci-dessus peuvent être crée par le code "problem1.py".

## I.2. Gradient optimal

**I.2.1.** Soit  $J(u) = \frac{1}{2}\langle Au, u \rangle - \langle b, u \rangle$ . On veut trouver  $\rho_k = \operatorname{argmin}_{\rho \geq 0} J(u_k - \rho \nabla J(u_k))$ . Soit  $r_k = \nabla J(u_k) = Au_k - b$ , on a

$$\begin{aligned}
 J(u_k - \rho \nabla J(u_k)) &= J(u_k - \rho r_k) \\
 &= \frac{1}{2} \langle A(u_k - \rho r_k), u_k - \rho r_k \rangle - \langle b, u_k - \rho r_k \rangle \\
 &= \frac{1}{2} \langle Au_k, u_k \rangle - \langle b, u_k \rangle + \frac{1}{2} \langle Au_k, -\rho r_k \rangle + \frac{1}{2} \langle -\rho Ar_k, u_k \rangle + \frac{1}{2} \langle -\rho Ar_k, -\rho r_k \rangle \\
 &\quad - \langle b, -\rho r_k \rangle \\
 &= J(u_k) - \frac{\rho}{2} [\langle Au_k, r_k \rangle + \langle Ar_k, u_k \rangle] + \frac{\rho^2}{2} \langle Ar_k, r_k \rangle + \rho \langle b, r_k \rangle \\
 &= J(u_k) + \frac{\rho^2}{2} \langle Ar_k, r_k \rangle + \rho [\langle b, r_k \rangle - \langle Au_k, r_k \rangle] \\
 &= J(u_k) + \frac{\rho^2}{2} \langle Ar_k, r_k \rangle + \rho [\langle b, r_k \rangle - \langle r_k - b, r_k \rangle] \\
 &= J(u_k) + \frac{\rho^2}{2} \langle Ar_k, r_k \rangle + \rho \langle r_k, r_k \rangle.
 \end{aligned}$$

Alors, la valeur que minimise cette fonction quadratique en  $\rho$  est

$$\rho_k = \frac{\langle r_k, r_k \rangle}{\langle Ar_k, r_k \rangle}$$

**I.2.2.** Pour les valeur  $A = \begin{pmatrix} 1 & 0 \\ 0 & \lambda \end{pmatrix}$  et  $b = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$  on a

$$\begin{pmatrix} r_{k1} \\ r_{k2} \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & \lambda \end{pmatrix} \begin{pmatrix} u_{k1} \\ u_{k2} \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} u_{k1} - 1 \\ \lambda u_{k2} - 1 \end{pmatrix}. \text{ Alors,}$$

$$\rho_k = \frac{(u_{k1} - 1)^2 + (\lambda u_{k2} - 1)^2}{(u_{k1} - 1)^2 + \lambda (\lambda u_{k2} - 1)^2} \quad (2)$$

À chaque itération, on actualise  $\rho_k$  en utilisant l'équation 2. Le figure 5 montre les résultats pour différentes condition initiales et pour le critère de arrête

$$\frac{\|r_k\|}{\|r_0\|} \leq 10^{-2}.$$




FIGURE 5 – Parcours du méthode de gradient à pas optimal.

**I.2.3.** Les figure 5 et 6 montre en échelle semi logarithme le rapport  $\frac{\|r_k\|}{\|r_0\|}$  en fonction de  $k$  pour les cas montrés dans les figure 5 et 6. Ces résultats peuvent être trouver en utilisant le code python disponible dans "problem2.py"




FIGURE 6 – Parcours du méthode de gradient à pas optimal.

**I.2.4.** Quand on met en œuvre le procédé de dichotomie pour l'équation 1, on trouve le résultat ci-dessous. Ce résultat a été géré par le code disponible dans le fichier "problem3.py".

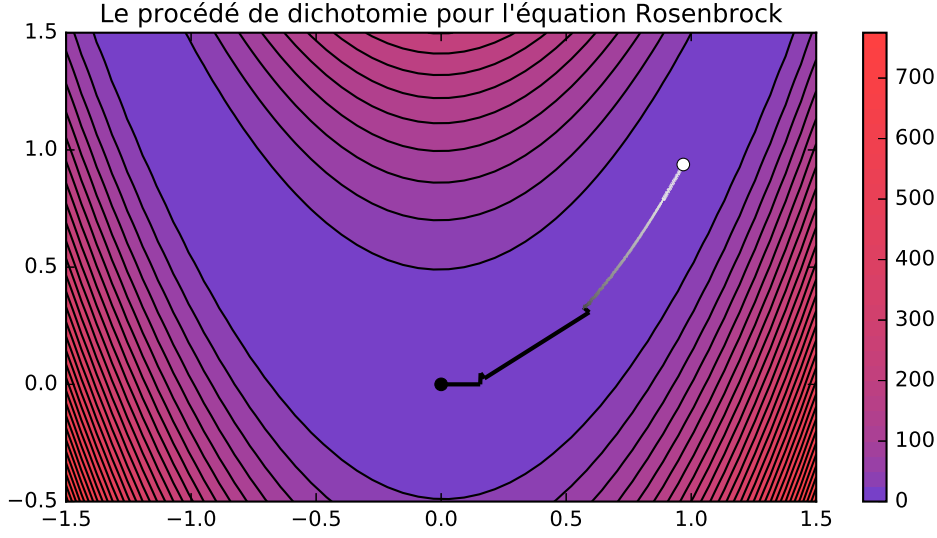


FIGURE 7 – Parcours obtenu à partir du procédé de dichotomie pour trouver le minimum global de la fonction de Rosenbrock.

## II. Méthodes newtoniennes

### II.1. Méthode de Newton

### II.2. Méthode de Gauss-Newton

**II.2.1.** On note le vecteur des paramètres  $\beta = \{\beta_1, \dots, \beta_{3K}\}$  de manière que  $\beta_j = \alpha_j$ ,  $\beta_{j+K} = \sigma_j$  et  $\beta_{j+2K} = x_j^0$ . Ainsi la matrice jacobienne  $Df(\beta)$  de dimension  $N \times 3K$  est donné par  $[Df(\beta)]_{ij} = \frac{\partial f_i(\beta)}{\partial \beta_j}$ . À fin de la calculer on rappelle la définition du vecteur  $f$   $f_i(\beta) = y_i - g(x_i, \beta)$  avec  $g(x_i, \beta) = \sum_{j=1}^K \alpha_j \exp\left(-\frac{1}{2} \frac{(x - x_j^0)^2}{\sigma_j^2}\right)$

$$\begin{aligned} [Df(\beta)]_{ij} &= \frac{\partial f_i(\beta)}{\partial \alpha_j} = -\exp\left(-\frac{1}{2} \frac{(x - x_j^0)^2}{\sigma_j^2}\right), \quad 1 \leq j \leq K \\ [Df(\beta)]_{i(K+j)} &= \frac{\partial f_i(\beta)}{\partial \sigma_j} = -\alpha_j \frac{(x - x_j^0)^2}{\sigma_j^3} \exp\left(-\frac{1}{2} \frac{(x - x_j^0)^2}{\sigma_j^2}\right), \quad 1 \leq j \leq K \\ [Df(\beta)]_{i(2K+j)} &= \frac{\partial f_i(\beta)}{\partial x_j^0} = -\alpha_j \frac{(x - x_j^0)}{\sigma_j^2} \exp\left(-\frac{1}{2} \frac{(x - x_j^0)^2}{\sigma_j^2}\right), \quad 1 \leq j \leq K \end{aligned}$$

On écrit le processus itératif à partir de l'algorithme de Newton  $\beta_{k+1} = \beta_k - [DF(\beta_k)]^{-1} F(\beta_k)$  en prenant l'approximation  $DF(\beta_k) = D[\nabla J(\beta_k)] = \nabla^2 J(\beta_k) \approx Df^T(u)Df(u)$  et en rappelant que  $F(\beta_k) = \nabla J(\beta_k) = Df^T(\beta_k)f(\beta_k)$

$$\beta_{k+1} = \beta_k - [Df^T(\beta_k)Df(\beta_k)]^{-1} Df^T(\beta_k)f(\beta_k), \quad k \geq 0$$

**II.2.2.** Avec les conditions initiales  $\alpha_1 = \alpha_2 = \sigma_1 = \sigma_2 = 1$ ,  $x_1^0 = 3$  et  $x_2^0 = 7$  la méthode de Gauss-Newton converge vers les valeurs suivantes

$$\begin{aligned} \alpha_1 &= 0.22213775, & \alpha_2 &= 0.98932187, & \sigma_1 &= 1.27128674, \\ \sigma_2 &= 2.64012043, & x_1^0 &= 2.57935799, & x_2^0 &= 9.16230523 \end{aligned}$$




FIGURE 8 – Nuage de points obtenue à partir des conditions initiales  $\alpha_1 = \alpha_2 = \sigma_1 = \sigma_2 = 1$ ,  $x_1^0 = 3$  et  $x_2^0 = 7$

**II.2.3.** D'après la figure 9 on voit la divergence de la méthode de Gauss-Newton avec des conditions initiales proches de la solution trouvée dans l'item précédent. De cette manière on voit la non-convergence locale de cette approximation de la Méthode de Newton classique.




FIGURE 9 – Nuage de points obtenue à partir des conditions initiales  $\alpha_1 = \alpha_2 = \sigma_1 = \sigma_2 = 1$ ,  $x_1^0 = 3$  et  $x_2^0 = 6$

Les résultats ci-dessus ont été créés par le code disponible dans "problem4.py".

### III. Application à l'équation de convection-diffusion

#### III.1. Différences schémas d'approximation

**III.1.1.** On remplace  $u_i^n$  par  $u(x_i, t_n)$  où  $u$  est une fonction régulière. On commence par le développement de Taylor au tour du point  $(x_i, t_n)$ . Pour le schéma

$$\frac{u_i^{n+1} - u_i^n}{\Delta t} + a \frac{u_{i+1}^n - u_{i-1}^n}{2\Delta x} - b \frac{u_{i+1}^n + u_{i-1}^n - 2u_i^n}{\Delta x^2} = 0, \text{ on a} \quad (3)$$

$$\begin{aligned} u(x_{i\pm 1}, t_n) &= u(x_i, t_n) \pm \Delta x \frac{\partial u}{\partial x}(x_i, t_n) + \frac{1}{2} \Delta x^2 \frac{\partial^2 u}{\partial x^2}(x_i, t_n) \pm \frac{1}{6} \Delta x^3 \frac{\partial^3 u}{\partial x^3}(x_i, t_n) \\ &\quad + \frac{1}{24} \Delta x^4 \frac{\partial^4 u}{\partial x^4}(x_i, t_n) + \mathcal{O}(\Delta x^5), \end{aligned}$$

$$u(x_i, t_{n+1}) = u(x_i, t_n) + \Delta t \frac{\partial u}{\partial t}(x_i, t_n) + \frac{1}{2} \Delta t^2 \frac{\partial^2 u}{\partial t^2}(x_i, t_n) + \mathcal{O}(\Delta t^3).$$

On remplace le développement dans l'erreur de troncature qui est défini comme

$$\begin{aligned} E &= \frac{u_i^{n+1} - u_i^n}{\Delta t} + a \frac{u_{i+1}^n - u_{i-1}^n}{2\Delta x} + b \frac{u_{i+1}^n + u_{i-1}^n - 2u_i^n}{\Delta x^2} \\ &= \frac{\partial u}{\partial t}(x_i, t_n) + a \frac{\partial u}{\partial x}(x_i, t_n) - b \frac{\partial^2 u}{\partial x^2}(x_i, t_n) + \mathcal{O}(\Delta t + \Delta x^2) \end{aligned}$$

Le erreur ci-dessus est dans le "standard" mentionné dans le Remarque 2.2.5 du polycopié, c'est à dire, pour une fonction régulière qui n'est pas solution de notre problème, la limite de l'erreur de troncature n'est pas nulle. Alors c'est schéma est consistante et d'ordre 1 en temps et 2 en espace. Pour le schéma

$$\frac{u_i^{n+1} - u_i^n}{\Delta t} + a \frac{u_{i+1}^{n+1} - u_{i-1}^{n+1}}{2\Delta x} - b \frac{u_{i+1}^{n+1} + u_{i-1}^{n+1} - 2u_i^{n+1}}{\Delta x^2} = 0, \quad (4)$$

on fait le développement au tour du point  $(x_i, t_{n+1})$  et on trouve

$$\begin{aligned} u(x_{i\pm 1}, t_{n+1}) &= u(x_i, t_{n+1}) \pm \Delta x \frac{\partial u}{\partial x}(x_i, t_{n+1}) + \frac{1}{2} \Delta x^2 \frac{\partial^2 u}{\partial x^2}(x_i, t_{n+1}) \pm \frac{1}{6} \Delta x^3 \frac{\partial^3 u}{\partial x^3}(x_i, t_{n+1}) \\ &\quad + \frac{1}{24} \Delta x^4 \frac{\partial^4 u}{\partial x^4}(x_i, t_{n+1}) + \mathcal{O}(\Delta x^5), \end{aligned}$$

$$u(x_i, t_n) = u(x_i, t_{n+1}) - \Delta t \frac{\partial u}{\partial t}(x_i, t_{n+1}) + \frac{1}{2} \Delta t^2 \frac{\partial^2 u}{\partial t^2}(x_i, t_{n+1}) + \mathcal{O}(\Delta t^3), \text{ et finalement}$$

$$\begin{aligned} E &= \frac{u_i^{n+1} - u_i^n}{\Delta t} + a \frac{u_{i+1}^{n+1} - u_{i-1}^{n+1}}{2\Delta x} - b \frac{u_{i+1}^{n+1} + u_{i-1}^{n+1} - 2u_i^{n+1}}{\Delta x^2} \\ &= \frac{\partial u}{\partial t}(x_i, t_{n+1}) + a \frac{\partial u}{\partial x}(x_i, t_{n+1}) - b \frac{\partial^2 u}{\partial x^2}(x_i, t_{n+1}) + \mathcal{O}(\Delta t + \Delta x^2). \end{aligned}$$

Par le même argument du schéma antérieur, ce schéma est consistant d'ordre 1 en temps et 2 en espace.

**III.1.2.** On commence par le schéma explicite 3. Pour la stabilité  $l^\infty$ , on va trouver les conditions CFL pour que le schéma vérifie le principe du maximum discret.

Soit  $k$  et  $l$  tel que

$$u_k^{n+1} = M = \max_j u_j^{n+1} \quad \text{et} \quad u_l^{n+1} = m = \min_j u_j^{n+1}$$

Notons que  $M$  est positif ou nul et  $m$  est négatif ou nul. On veut trouver les conditions pour que

$$M \leq \max(0, \max_j u_j^n) \tag{5}$$

$$\text{et } \min(0, \min_j u_j^n) \leq m. \tag{6}$$

On commence l'analyse par l'inégalité 5. Elle est trivialement vérifiée si  $M = 0$ . Alors, on analyse le cas où  $M \neq 0$ . Le maximum de  $u_j^{n+1}$  pour tout  $j \in \{i_{\max} - 1, i_{\max} + 1\}$  est atteint en un élément  $k \in \{i_{\max}, i_{\max}\}$ . Alors

$$\frac{M - u_k^n}{\Delta t} + a \frac{u_{k+1}^n - u_{k-1}^n}{2\Delta x} - b \frac{u_{k+1}^n + u_{k-1}^n - 2u_k^n}{\Delta x^2} \leq 0$$

soit

$$M \leq \left( -\frac{a\Delta t}{2\Delta x} + \frac{b\Delta t}{\Delta x^2} \right) u_{k+1}^n + \left( 1 - \frac{2b\Delta t}{\Delta x^2} \right) u_k^n + \left( \frac{a\Delta t}{2\Delta x} + \frac{b\Delta t}{\Delta x^2} \right) u_{k-1}^n$$

Pour que le schéma de droite soit une combinaison convexe de  $u_n$  et l'inégalité 5 soit vérifiée on les conditions ci-dessus.

$$\Delta x \leq \frac{2b}{a} \quad , \quad \Delta x \geq -\frac{2b}{a} \quad \text{et} \quad \Delta t \leq \frac{\Delta x^2}{2b}.$$

Pour vérifiée l'inégalité 6, on remplace  $u^n$  par  $-u^n$  et  $M$  par  $-m$ .

Pour la stabilité du schéma 4 en  $l^\infty$ , on voit que c'est un schéma implicite qui vérifie le principe du maximum. Alors, il est stable.

Pour la stabilité du schéma 3 en  $l^2$ , on a, pour la transformé de Fourier,

$$\hat{u}^{n+1}(k) = \left( 1 - \frac{a\Delta t}{2\Delta x} (e^{2i\pi k\Delta x} - e^{-2i\pi k\Delta x}) + \frac{b\Delta t}{\Delta x^2} (e^{2i\pi k\Delta x} + e^{-2i\pi k\Delta x} - 2) \right) \hat{u}^n(k)$$

Autrement dit

$$\hat{u}^{n+1}(k) = A(k)\hat{u}^n(k) = A(k)^{n+1}\hat{u}^0(k) \quad \text{avec} \quad A(k) = \left( 1 - \frac{ia\Delta t}{2\Delta x} \sin(2\pi k\Delta x) + \frac{4b\Delta t}{\Delta x^2} \sin^2(\pi k\Delta x) \right)$$

Comme  $\|A(k)\| \leq 1$  pour tout mode de Fourier  $k$ , la formule de Plancherel permet de conclure à la stabilité  $l^2$  du schéma. (Voir polycopié page 36).



## III.2. Schéma implicite

III.2.1. On peut récrire le schéma implicite comme

$$u_i^n = \left( \frac{a\Delta t}{2\Delta x} - \frac{b\Delta t}{\Delta x^2} \right) u_{i+1}^{n+1} + \left( 1 + \frac{2b\Delta t}{\Delta x^2} \right) u_i^{n+1} + \left( -\frac{a\Delta t}{2\Delta x} - \frac{b\Delta t}{\Delta x^2} \right) u_{i-1}^{n+1}.$$

On pose  $\gamma = \frac{a\Delta t}{2\Delta x}$  et  $\delta = \frac{b\Delta t}{\Delta x^2}$ . Alors pour  $U^n = MU^{n+1}$ , où  $U^n = \begin{pmatrix} u_{-i_{\max}}^n \\ \vdots \\ u_{i_{\max}}^n \end{pmatrix}$ , on trouve

$$M = \begin{pmatrix} 1+2\delta & \gamma-\delta & & & \\ -(\gamma+\delta) & 1+2\delta & \gamma-\delta & & \\ & -(\gamma+\delta) & \ddots & \ddots & \\ & & \ddots & \ddots & \gamma-\delta \\ & & & -(\gamma+\delta) & 1+2\delta \end{pmatrix}$$

III.2.2. On définit  $M^S = \frac{1}{2}(M + M^T)$

$$M^S = \begin{pmatrix} 1+2\delta & -\delta & & & \\ -\delta & 1+2\delta & -\delta & & \\ & -\delta & \ddots & \ddots & \\ & & \ddots & \ddots & -\delta \\ & & & -\delta & 1+2\delta \end{pmatrix} \quad (7)$$

D'après [1],  $M$  est positive définit si et seulement si  $M^S$  y est. D'après [2], comme  $\|1+2\delta\| > \|-\delta\| + \|-\delta\|$ ,  $M^S$  est définit positive, alors  $M$  est définit positive. Ce qu'implique que  $M$  est inversible.

III.2.3. La solution a été calculé e la figure crée par le code disponible sur "problem5.py".




FIGURE 10 – Représentation de la solution implicite pour  $\Delta x = 0.1$ ,  $\Delta t = 10^{-4}$  et  $n = 10^5$ . Les fonctions sont superposées et l'intensité de la couleur rouge augmente avec le temps.

## IV. Application à l'équation de la chaleur non linéaire

### IV.1. Schéma implicite linéaire

IV.1.1. On peut récrire le schéma comme

$$u_i^n = \left(-\frac{b\Delta t}{\Delta x^2}\right) u_{i+1}^{n+1} + \left(1 + 2\frac{b\Delta t}{\Delta x^2}\right) u_i^{n+1} + \left(-\frac{b\Delta t}{\Delta x^2}\right) u_{i-1}^{n+1} + u_i^{n+1} (u_i^n)^3 \Delta t.$$

Ainsi, on peut écrire  $U^n = (A + \Delta t \text{ diag}((u_{-i_{\max}}^n)^3, \dots, (u_{i_{\max}}^n)^3)) U^{n+1}$ , où  $U^n = \begin{pmatrix} u_{-i_{\max}}^n \\ \vdots \\ u_{i_{\max}}^n \end{pmatrix}$ ,

$$\delta = \frac{b\Delta t}{\Delta x^2} \text{ et } A = \begin{pmatrix} 1 + 2\delta & -\delta & & & \\ -\delta & 1 + 2\delta & -\delta & & \\ & -\delta & \ddots & \ddots & \\ & & \ddots & \ddots & -\delta \\ & & & -\delta & 1 + 2\delta \end{pmatrix}.$$

IV.1.2. La solution a été calculé e la figure crée par le code disponible sur "problem5.py".

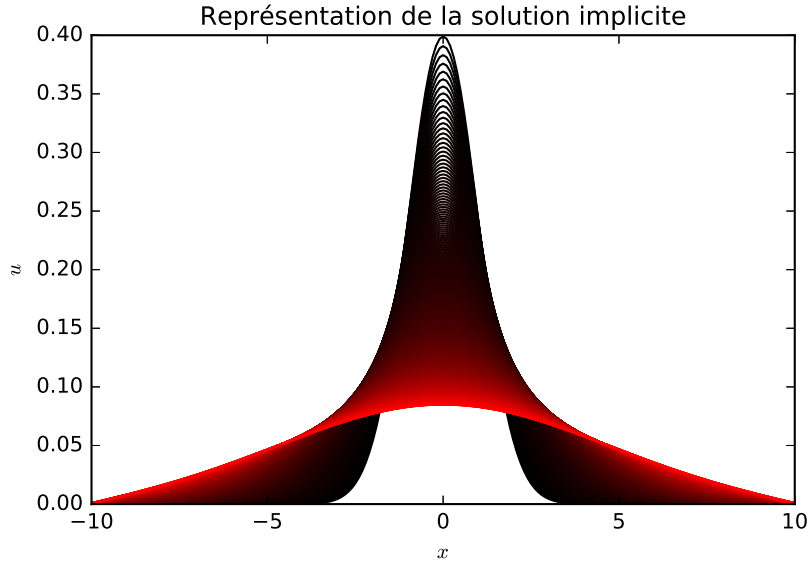


FIGURE 11 – Représentation de la solution implicite pour  $\Delta x = 0.1$ ,  $\Delta t = 10^{-4}$  et  $n = 10^5$ . Les fonctions sont superposées et l'intensité de la couleur rouge augmente avec le temps.

### IV.2. Schéma pour l'équation stationnaire

IV.2.1. On va écrire la fonction  $G$  comme

$$G_i(U) = -b \frac{u_{i+1} + u_{i-1} - 2u_i}{\Delta x^2} + u_i^4 - Q_i, \forall i \in [-i_{\max}, i_{\max}]$$

de façon que pour  $G = (G_{-i_{\max}}, \dots, G_{i_{\max}})$ , on a  $G(U) = 0$ .

IV.2.2. On sait que  $[DG(\beta)]_{ij} = \frac{\partial G_i(\beta)}{\partial \beta_j}$ . Pour  $Q=1$  et  $\theta = \frac{b}{\Delta x^2}$ , on a

$$DG(U) = \begin{pmatrix} 2\theta + 4u_{-i_{\max}}^3 & -\theta & & & \\ -\theta & 2\theta + 4u_{-i_{\max}+1}^3 & -\theta & & \\ & -\theta & \ddots & \ddots & \\ & & \ddots & \ddots & -\theta \\ & & & -\theta & 2\theta + 4u_{i_{\max}}^3 \end{pmatrix}.$$

Pour l'algorithme de Newton on aura

$$U^{k_1} = U^k - (DG(U^k))^{-1}G(U^k), \text{ ou alors}$$

$$G(U^k) = DG(U^k)(U^k - U^{k+1}).$$

Le choix de la fonction initiale est arbitraire et on peut utiliser par exemple une parabole  $u_0(x) = 1 - \frac{x^2}{100}$ . On voit la convergence vers une fonction proche que 1 au milieu et avec une courbature qui compense les conditions de Dirichlet aux bords.

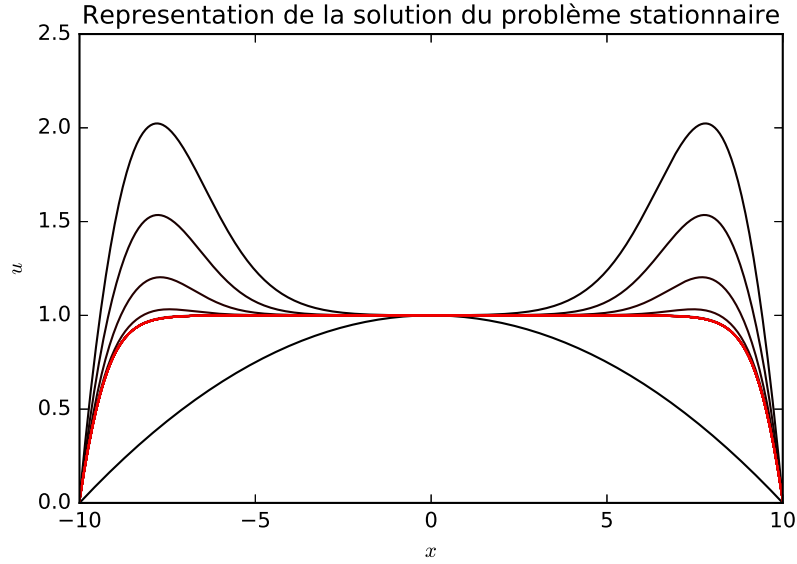


FIGURE 12 – Représentation de la solution du problème stationnaire avec  $\Delta x = 0.01$  et  $n = 20$  itérations. Les fonctions sont superposées et l'intensité de la couleur rouge augmente avec le temps.

Le calcul et la figure ont été faits par le code "problem6.py".

## Références

- [1] Weisstein, Eric W. *Positive Definite Matrices*. From MathWorld—A Wolfram Web Resource. <http://mathworld.wolfram.com/PositiveDefiniteMatrix.html>
- [2] Milica Andelić and C. M. da Fonseca. *Sufficient Conditions for Positive Definiteness of Tridiagonal Matrices Revisited*. [http://www.mat.uc.pt/~cmf/papers/tri\\_positive\\_definite\\_revisited.pdf](http://www.mat.uc.pt/~cmf/papers/tri_positive_definite_revisited.pdf)